

ĐẠI HỌC QUỐC GIA TP HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Báo cáo về dữ liệu

Đề tài: Xây dựng Hệ thống phân loại bình luận tiêu cực

Môn học: Nhập môn học máy

Sinh viên thực hiện:

23120030 - Trần Thanh Đạt

23120041 - Lê Minh Hải

23120048 - Phan Hoàng Quốc Huy

23120088 - Cao Tiến Thành

23122006 - Lưu Thượng Hồng

Giáo viên hướng dẫn:

TS. Bùi Tiến Lên

ThS. Lê Nhật Nam

Ngày 3 tháng 6 năm 2026



Mục lục

1	Giới thiệu bài toán	1
2	Phương pháp và nguồn thu thập dữ liệu	1
2.1	Nguồn gốc và cấu trúc tập dữ liệu	1
2.2	Quy trình làm sạch cấu trúc	2
2.3	Tiền xử lý ngôn ngữ tự nhiên (NLP Preprocessing)	2
2.4	Đảm bảo chất lượng dữ liệu	4
2.5	Lưu trữ và quản lý dữ liệu	4
3	Phân tích khám phá dữ liệu (EDA)	5
3.1	Thống kê mô tả tổng quan	5
3.2	Phân tích phân bố nhãn	6
3.3	So sánh phân bố nhãn giữa các tập	7
3.4	Thống kê độ dài văn bản theo nhãn	8
3.5	Phân tích tương quan giữa độ dài văn bản và nhãn	10
3.6	Phân tích tần suất từ và ngữ nghĩa theo nhãn	10
3.7	Phát hiện điểm bất thường (Outliers)	12
4	Tổng kết	12
	Tài liệu	14

Danh sách bảng

1	Hệ thống nhãn và phân phối mẫu trong tập dữ liệu ViHSD	1
2	Phân phối mẫu sau bước làm sạch cấu trúc	2
3	Tổng kết số liệu sau pipeline tiền xử lý NLP	4
4	Kết quả kiểm tra chất lượng tập dữ liệu sau xử lý hoàn chỉnh	4
5	Thống kê tổng quan các tập dữ liệu sau xử lý	5
6	Thống kê mô tả độ dài văn bản (tập train)	6
7	Thống kê độ dài văn bản và số từ theo nhãn (tập train)	8
8	Hệ số tương quan point-biserial giữa độ dài ký tự và từng nhãn (tập train)	10
9	Thống kê các điểm bất thường trong tập train	12

Danh sách hình vẽ

1	Cấu trúc thư mục lưu trữ dữ liệu	5
2	Phân bố nhãn trong tập train: biểu đồ cột (trái) và biểu đồ tròn (phải)	7
3	So sánh tỉ lệ phân bố nhãn (%) giữa tập Train, Dev và Test	8
4	Histogram phân bố độ dài ký tự (trái) và số từ (phải) theo nhãn	9
5	Boxplot độ dài ký tự (trái) và số từ (phải) theo nhãn	9
6	Top 20 từ đơn phổ biến nhất theo từng nhãn	10
7	Top 20 cụm 2 từ (bigram) phổ biến nhất theo từng nhãn	11
8	Word Cloud từ vựng phổ biến theo từng nhãn	11

1 Giới thiệu bài toán

Đề án xây dựng hệ thống **phát hiện ngôn từ thù ghét** (Hate Speech Detection) tự động từ văn bản tiếng Việt, phân loại bình luận mạng xã hội thành ba lớp: sạch (CLEAN), xúc phạm (OFFENSIVE) và thù ghét (HATE). Bài toán được giải quyết thông qua quy trình kỹ thuật toàn diện: thu thập dữ liệu từ bộ dữ liệu ViHSD, tiền xử lý đặc thù cho ngôn ngữ mạng (teencode, từ lóng, ký tự nhiều), thực nghiệm so sánh ít nhất ba thuật toán học máy và đánh giá hiệu năng qua các chỉ số chuyên biệt. Sản phẩm cuối cùng là một ứng dụng Web triển khai trên nền tảng Cloud, giúp tự động hóa việc lọc và phân loại nội dung độc hại trong bối cảnh bùng nổ mạng xã hội tại Việt Nam.

2 Phương pháp và nguồn thu thập dữ liệu

2.1 Nguồn gốc và cấu trúc tập dữ liệu

Nhằm đảm bảo tính minh bạch và khả năng tái tạo kết quả, phần này trình bày nguồn gốc học thuật và cấu trúc ban đầu của tập dữ liệu được sử dụng trong đề án. Nhóm sử dụng bộ dữ liệu **ViHSD** (*Vietnamese Hate Speech Detection*) — một trong những tập dữ liệu mã nguồn mở quy mô lớn tiêu biểu cho bài toán phát hiện ngôn từ thù ghét tiếng Việt, được công bố bởi Luu và cộng sự Luu et al., 2021 thuộc phòng thí nghiệm UIT-NLP, Đại học Công nghệ Thông tin – ĐHQG TP.HCM. ViHSD được thu thập từ các nền tảng mạng xã hội phổ biến tại Việt Nam (Facebook, YouTube, TikTok), bao gồm 33,400 bình luận được gán nhãn thủ công. Hệ thống nhãn gồm ba lớp được mô tả chi tiết trong Bảng 1.

Bảng 1: Hệ thống nhãn và phân phối mẫu trong tập dữ liệu ViHSD

Nhãn	Tên nhãn	Mô tả	Train	Dev	Test
0	CLEAN	Bình luận sạch, không chứa nội dung tiêu cực	19,886	2,190	5,548
1	OFFENSIVE	Bình luận có ngôn từ xúc phạm, thô tục	1,606	212	444
2	HATE	Ngôn từ thù ghét nhắm vào cá nhân hoặc nhóm	2,556	270	688
Tổng cộng			24,048	2,672	6,680

Bộ dữ liệu được phân chia thành ba tập định dạng CSV sẵn sàng cho mục đích huấn luyện và đánh giá: tập *train* chứa 24,048 mẫu, tập *dev* chứa 2,672 mẫu và tập *test* chứa 6,680 mẫu, với cấu trúc

thống nhất gồm hai cột chính là *free_text* (nội dung bình luận thô) và *label_id* (nhãn số nguyên tương ứng).

Việc lựa chọn ViHSD vì đây là một benchmark chuẩn đã được cộng đồng nghiên cứu xử lý ngôn ngữ tự nhiên tiếng Việt (NLP) kiểm chứng, giúp đảm bảo tính so sánh với các công trình liên quan. Từ đó, bước tiếp theo cần tiến hành kiểm tra và làm sạch cấu trúc cơ bản nhằm xác định mức độ nhiễu cấu trúc tồn tại trong bộ dữ liệu trước khi đi vào xử lý ngôn ngữ chuyên sâu.

2.2 Quy trình làm sạch cấu trúc

Bước đầu tiên trong pipeline, nhóm kiểm tra và loại bỏ các quan sát không hợp lệ ở mức cấu trúc nhằm đảm bảo tính toàn vẹn của dữ liệu đầu vào. Quy trình gồm hai bước tuần tự được áp dụng đồng nhất cho cả ba tập:

1. **Xử lý giá trị thiếu (Missing Values):** Các dòng có cột *free_text* rỗng hoặc null bị loại bỏ hoàn toàn, vì không thể thực hiện phân loại trên văn bản không có nội dung. Kết quả: tập *train* loại 2 dòng null; *dev* và *test* không có null.
2. **Xử lý dữ liệu trùng lặp (Duplicates):** Các dòng hoàn toàn giống nhau về cả nội dung lẫn nhãn bị loại bỏ để tránh mô hình bị overfit trên các mẫu lặp. Kết quả: tập *train* loại 1,356 dòng, *dev* loại 21 dòng, *test* loại 98 dòng.

Sau bước làm sạch cấu trúc, phân phối nhãn trong ba tập được thể hiện tại Bảng 2.

Bảng 2: Phân phối mẫu sau bước làm sạch cấu trúc

Nhãn	Train	Dev	Test
CLEAN (0)	18,652	2,171	5,461
OFFENSIVE (1)	1,543	210	440
HATE (2)	2,495	270	681
Tổng	22,690	2,651	6,582

2.3 Tiền xử lý ngôn ngữ tự nhiên (NLP Preprocessing)

Do đặc thù của văn bản người dùng tự tạo (UGC) tiếng Việt chứa nhiều dạng nhiễu phi ngữ nghĩa như emoji, URL, teencode và ký tự lặp, nhóm thiết kế một pipeline chuẩn hóa văn bản gồm 11 bước tuần tự:

1. **Chuyển chữ thường (Lowercasing):** Đồng nhất hóa toàn bộ ký tự về dạng chữ thường để loại bỏ phân biệt hoa/thường.
2. **Loại bỏ HTML tags:** Xóa các thẻ HTML còn sót lại từ quá trình thu thập dữ liệu bằng biểu thức chính quy.
3. **Loại bỏ URL:** Xóa các đường dẫn web dạng `http://` và `www.` không mang thông tin ngữ nghĩa.
4. **Loại bỏ địa chỉ email:** Xóa các chuỗi có dạng `user@domain.com`.
5. **Loại bỏ số điện thoại:** Xóa các số điện thoại Việt Nam dạng `0xxxxxxxx` hoặc `+84xxxxxxxx`.
6. **Loại bỏ emoji:** Xóa các ký tự Unicode thuộc khối emoticons và pictographs.
7. **Chuẩn hóa ký tự lặp:** Rút gọn các chuỗi ký tự lặp liên tiếp quá 2 lần (ví dụ: `"đẹppppp"` → `"đẹp"`).
8. **Thay thế Teencode:** Tra cứu và thay thế từ điển 106 từ viết tắt và từ lóng phổ biến (ví dụ: `"ko"` → `"không"`, `"dc"` → `"được"`).
9. **Loại bỏ ký tự đặc biệt:** Chỉ giữ lại chữ cái tiếng Việt, chữ số và khoảng trắng; loại bỏ các ký tự còn lại.
10. **Chuẩn hóa khoảng trắng:** Thu gọn nhiều khoảng trắng liên tiếp thành một và xóa khoảng trắng đầu/cuối chuỗi.
11. **Loại bỏ dòng rỗng sau NLP:** Các mẫu trở thành chuỗi rỗng sau khi xử lý (thường là những bình luận chỉ chứa thuần emoji hoặc URL) được loại bỏ.

Sau khi áp dụng pipeline, kết quả tổng hợp được thể hiện tại Bảng 3. Các mẫu bị loại sau NLP chủ yếu thuộc lớp CLEAN vì đây là những bình luận ngắn chỉ chứa thuần emoji hoặc URL. Tập dữ liệu sau xử lý được lưu dưới định dạng `*_clean.csv`, sẵn sàng cho bước Phân tích Khám phá Dữ liệu (EDA).

Bảng 3: Tổng kết số liệu sau pipeline tiền xử lý NLP

Nhãn	Train		Dev		Test	
	Trước	Sau	Trước	Sau	Trước	Sau
CLEAN (0)	18,652	18,473	2,171	2,153	5,461	5,406
OFFENSIVE (1)	1,543	1,542	210	210	440	440
HATE (2)	2,495	2,495	270	270	681	681
Tổng	22,690	22,510	2,651	2,633	6,582	6,527
Loại bỏ	180		18		55	
Độ dài TB (ký tự)	48.1		47.1		47.4	
Số từ TB	11.7		11.5		11.5	

2.4 Đảm bảo chất lượng dữ liệu

Sau khi hoàn tất toàn bộ pipeline xử lý, nhóm thực hiện kiểm tra chất lượng tự động trên tập dữ liệu cuối cùng (`*_clean.csv`) theo năm tiêu chí định lượng. Bảng 4 tổng hợp kết quả kiểm tra.


Bảng 4: Kết quả kiểm tra chất lượng tập dữ liệu sau xử lý hoàn chỉnh

Tiêu chí kiểm tra	Train	Dev	Test
Tổng mẫu	22,510	2,633	6,527
Giá trị null còn lại	0	0	0
Chuỗi rỗng còn lại	0	0	0
Dòng trùng lặp còn lại	0	0	0
Nhãn nằm ngoài $\{0, 1, 2\}$	0	0	0
Outliers độ dài ($> 3\sigma$)	108	65	136
Mẫu rất ngắn (< 3 từ)	1,460	211	470

Kết quả cho thấy bộ dữ liệu đạt năm tiêu chí đầu hoàn toàn: không còn null, chuỗi rỗng, trùng lặp hay nhãn không hợp lệ. Về ngoại lệ, 108 mẫu train có độ dài vượt ngưỡng 3σ (tương đương 0.48%) — đây là các bình luận dài bất thường, chủ yếu là chuỗi spam hoặc nội dung được sao chép nhiều lần; nhóm quyết định giữ lại vì chúng vẫn mang nhãn hợp lệ và chiếm tỉ lệ rất nhỏ. Tương tự, các mẫu rất ngắn (< 3 từ) chiếm khoảng 6.5–8% và phần lớn thuộc nhãn CLEAN, phản ánh đặc tính tự nhiên của bình luận mạng xã hội.

2.5 Lưu trữ và quản lý dữ liệu

Toàn bộ dữ liệu được lưu trữ trong thư mục `data/` tại thư mục gốc của dự án. Cấu trúc thư mục dữ liệu được minh họa ở Hình 1.



Hình 1: Cấu trúc thư mục lưu trữ dữ liệu

3 Phân tích khám phá dữ liệu (EDA)

3.1 Thống kê mô tả tổng quan

Bảng 5 tóm tắt thông tin cơ bản của ba tập dữ liệu sau xử lý. Bộ dữ liệu cuối cùng không còn giá trị null hay bản ghi trùng lặp ở bất kỳ tập nào.

Bảng 5: Thống kê tổng quan các tập dữ liệu sau xử lý

Tập	Số mẫu	Số cột	Giá trị null	Bản ghi trùng
Train	22,510	3	0	0
Dev	2,633	3	0	0
Test	6,527	3	0	0
Tổng	31,670	—	0	0

Bảng 6 trình bày thống kê mô tả đầy đủ của thuộc tính số trong bộ dữ liệu, được tính từ cột *free_text_clean* trên tập train.


Bảng 6: Thống kê mô tả độ dài văn bản (tập train)

Thống kê	Độ dài (ký tự)	Số từ
Số mẫu	22,510	22,510
Min	1	1
Max	7,084	1,550
Mean	48.1	11.7
Median	33	8
Std	84.2	19.4
Q1 (25%)	19	5
Q3 (75%)	56	14
IQR	37	9

Chỉ số $\text{std}/\text{mean} = 1.75$ cho độ dài ký tự xác nhận phân bố lệch phải rõ rệt — phần lớn bình luận rất ngắn gọn nhưng tồn tại một số bình luận cực dài kéo trung bình lên cao.

3.2 Phân tích phân bố nhãn


Bộ dữ liệu ViHSD sau xử lý hoàn chỉnh có tỉ lệ phân bố nhãn được thể hiện trong Hình 2. Nhãn **CLEAN** (không tiêu cực) chiếm đa số tuyệt đối với 82.1% tổng số mẫu trong tập train, trong khi nhãn **OFFENSIVE** (tiêu cực) chiếm 6.9% và nhãn **HATE** (thù ghét) chiếm 11.1%. Sự chênh lệch tỉ lệ rõ rệt này chứng tỏ bộ dữ liệu bị **mất cân bằng nghiêm trọng** (highly imbalanced). Hệ quả trực tiếp là nếu không có biện pháp xử lý, mô hình học máy sẽ có xu hướng dự đoán thiên về lớp đa số, làm giảm độ chính xác trên các lớp thiểu số. Do đó, các kỹ thuật xử lý mất cân bằng như class weighting hoặc oversampling cần được cân nhắc trong giai đoạn huấn luyện.



Hình 2: Phân bố nhãn trong tập train: biểu đồ cột (trái) và biểu đồ tròn (phải)

3.3 So sánh phân bố nhãn giữa các tập

Hình 3 so sánh tỉ lệ phần trăm của từng nhãn giữa ba tập train, dev và test. Phân bố tỉ lệ các nhãn gần như **tương đồng** qua cả ba tập: nhãn CLEAN dao động quanh 82%, OFFENSIVE quanh 7% và HATE quanh 11%. Sự nhất quán này xác nhận rằng quá trình phân chia tập dữ liệu gốc đã duy trì tốt tính đại diện — mô hình học từ tập train sẽ phản ánh đúng cấu trúc phân bố trên tập dev và test, giúp quá trình đánh giá có giá trị thực tiễn.




Hình 3: So sánh tỉ lệ phân bố nhãn (%) giữa tập Train, Dev và Test

3.4 Thống kê độ dài văn bản theo nhãn


Bảng 7 trình bày thống kê mô tả độ dài văn bản (ký tự) và số từ theo từng nhãn trên tập train. Hình 4 và Hình 5 trực quan hóa phân bố này qua histogram và boxplot.

Bảng 7: Thống kê độ dài văn bản và số từ theo nhãn (tập train)

Nhãn	Độ dài (ký tự)				Số từ			
	Min	Max	Mean	Median	Min	Max	Mean	Median
CLEAN (0)	1	7,084	43.74	32.0	1	1,550	10.59	8.0
OFFENSIVE (1)	1	368	43.96	30.0	1	91	10.89	8.0
HATE (2)	4	671	83.37	59.0	1	163	20.29	14.0



Hình 4: Histogram phân bố độ dài ký tự (trái) và số từ (phải) theo nhãn



Hình 5: Boxplot độ dài ký tự (trái) và số từ (phải) theo nhãn

Một số nhận xét nổi bật từ thống kê và biểu đồ:

- **Phân bố lệch phải (right-skewed):** Median luôn nhỏ hơn Mean ở cả ba nhãn, cho thấy phần lớn bình luận khá ngắn nhưng một số lượng nhỏ bình luận rất dài kéo giá trị trung bình lên cao.
- **Nhãn HATE có độ dài vượt trội:** Bình luận thù ghét có độ dài trung bình (83.37 ký tự, 20.29 từ) gần gấp đôi so với hai nhãn còn lại, gợi ý rằng ngôn từ thù ghét thường được diễn đạt trong các câu dài hơn.
- **Ngoại lệ (outliers):** Boxplot cho thấy lượng lớn các outlier phía trên râu trên, đặc biệt ở nhãn CLEAN, chủ yếu là spam hoặc nội dung sao chép lặp lại.

3.5 Phân tích tương quan giữa độ dài văn bản và nhãn

Để kiểm định mối quan hệ giữa độ dài văn bản và nhãn phân loại, nhóm thực hiện kiểm định ANOVA một chiều và tính hệ số tương quan point-biserial giữa độ dài ký tự và từng nhãn trên tập train. Kết quả được tổng hợp tại Bảng 8.


Bảng 8: Hệ số tương quan point-biserial giữa độ dài ký tự và từng nhãn (tập train)

Nhãn	Hệ số r	p-value	Kết luận
CLEAN (0)	-0.112	< 0.001	Tương quan âm yếu, có ý nghĩa
OFFENSIVE (1)	-0.014	0.043	Không có tương quan thực tế
HATE (2)	+0.148	< 0.001	Tương quan dương yếu, có ý nghĩa
<i>Kiểm định ANOVA một chiều: $F = 251.21, p < 0.001$</i>			


Kiểm định ANOVA cho thấy sự khác biệt về độ dài văn bản giữa các nhóm nhãn là **có ý nghĩa thống kê** ($F = 251.21, p < 0.001$). Bình luận thuộc nhãn HATE có xu hướng dài hơn đáng kể (mean = 83.4 ký tự, median = 59) so với CLEAN (mean = 43.7, median = 32) và OFFENSIVE (mean = 44.0, median = 30). Nhãn OFFENSIVE không có tương quan thực tế với độ dài ($r = -0.014$). Nhận xét này nhất quán với thống kê ở Bảng 7: ngôn từ thù ghét thường kèm theo lập luận hoặc mô tả chi tiết. Do đó, **độ dài văn bản có tiềm năng là một đặc trưng phụ trợ** (auxiliary feature) giúp phân biệt nhãn HATE với hai nhãn còn lại.

3.6 Phân tích tần suất từ và ngữ nghĩa theo nhãn

Hình 6 và Hình 7 trình bày Top 20 từ đơn (unigram) và cụm 2 từ (bigram) phổ biến nhất theo từng nhãn. Hình 8 minh họa Word Cloud trực quan.



Hình 6: Top 20 từ đơn phổ biến nhất theo từng nhãn



Hình 7: Top 20 cụm 2 từ (bigram) phổ biến nhất theo từng nhãn



Hình 8: Word Cloud từ vựng phổ biến theo từng nhãn

Các nhận xét rút ra từ phân tích tần suất:

- **Stopwords vẫn được giữ lại có chủ đích:** Các từ xuất hiện nhiều nhất ở cả ba nhãn chủ yếu là hư từ tiếng Việt như “không”, “là”, “mà”, “có”. Nhóm không loại bỏ stopwords vì chúng vẫn mang tín hiệu ngữ nghĩa quan trọng trong bài toán phát hiện ngôn từ thù ghét. Ví dụ, từ “không” có thể thay đổi hoàn toàn cực tính của câu, trong khi các từ như “mà” hay “thôi” thường thể hiện sắc thái tiêu cực trong khẩu ngữ. Việc giữ lại các từ này giúp bảo toàn ngữ cảnh và có thể cải thiện hiệu quả phân loại của mô hình.
- **Sự khác biệt trong từ vựng theo nhãn:** Nhãn CLEAN thể hiện sự giao tiếp mang tính xây dựng, với sự xuất hiện của các đại từ lịch sự như “anh”, “em”, “bạn”. Ngược lại, nhãn OFFENSIVE sử dụng các từ ngữ cảm thán mạnh và cách xưng hô suồng sã như “tao”, “nó”. Nhãn HATE chứa các từ ngữ mang tính công kích trực tiếp vào danh tính hoặc đặc điểm của đối tượng.
- **Bigram phân biệt rõ nhãn hơn unigram:** Phân tích bigram cho thấy nhãn CLEAN gắn với văn hóa giao tiếp cộng đồng tích cực (“mọi người”, “anh em”); nhãn OFFENSIVE bị thống

trị bởi các cụm chữ thề (“*mẹ nó*”, “*đ mẹ*”); nhãn HATE chứa các cụm ngôn ngữ phân biệt và xúc phạm nhóm.

3.7 Phát hiện điểm bất thường (Outliers)

Phân tích outliers trên tập train theo ba tiêu chí được tổng hợp tại Bảng 9.

Bảng 9: Thống kê các điểm bất thường trong tập train

Loại bất thường	Số mẫu	Tỉ lệ	Hướng xử lý
Câu rất ngắn (≤ 2 từ)	1,460	6.49%	Giữ lại
Câu rất dài (> 100 từ)	17	0.08%	Cắt ngắn khi dùng Transformer
Nhiều ký tự lạ ($>40\%$ ký tự đặc biệt)	98	0.44%	Cần nhắc loại bỏ

Nhóm quyết định **giữ lại** toàn bộ ba nhóm outlier này trong tập dữ liệu hiện tại. Các câu rất ngắn vẫn mang nhãn hợp lệ và có thể chứa đặc trưng quan trọng (một từ chữ thề đủ để phân loại). Các câu rất dài (17 mẫu, 0.08%) sẽ được xử lý cắt ngắn ở bước mã hóa (tokenization) khi sử dụng mô hình Transformer có giới hạn chiều dài token đầu vào. Các câu chứa nhiều ký tự lạ sẽ được cân nhắc loại bỏ hoặc xử lý thêm.

4 Tổng kết

Thông qua việc thực hiện quy trình từ thu thập, làm sạch đến phân tích khám phá dữ liệu (EDA) trên bộ dữ liệu ViHSD, nhóm đã xây dựng được một nền tảng dữ liệu vững chắc cho bài toán phát hiện ngôn từ thù ghét. Các kết luận quan trọng rút ra bao gồm:

- **Độ tin cậy của dữ liệu:** Quy trình làm sạch hai lớp (cấu trúc và NLP) đã loại bỏ hoàn toàn các giá trị null và trùng lặp, đồng thời chuẩn hóa được các nhiễu đặc thù của mạng xã hội như teencode và ký tự lặp, đảm bảo dữ liệu đầu vào cho mô hình có chất lượng cao.
- **Thách thức về sự cân bằng:** Sự chênh lệch lớn giữa nhãn CLEAN (82.1%) và các nhãn tiêu cực (HATE, OFFENSIVE) là đặc điểm cốt lõi của bài toán. Điều này đòi hỏi các chiến lược xử lý mất cân bằng nghiêm ngặt ở giai đoạn huấn luyện mô hình.
- **Đặc trưng phân biệt nhãn:**

- *Về độ dài*: Bình luận HATE có độ dài trung bình vượt trội và có ý nghĩa thống kê ($p < 0.001$), gợi ý việc sử dụng thông tin độ dài như một thuộc tính bổ trợ hữu hiệu.
- *Về ngữ nghĩa*: Sự khác biệt rõ rệt trong hệ thống từ vựng và cụm từ (bigram) giữa các nhãn xác nhận khả năng phân loại dựa trên đặc trưng ngôn ngữ.
- **Chiến lược tiền xử lý tối ưu**: Nhóm quyết định loại bỏ triệt để các emoji và ký tự đặc biệt để giảm nhiễu, tập trung tối đa vào nội dung văn bản thuần túy. Ngược lại, việc giữ lại các từ dừng (stopwords) được chứng minh là cần thiết để bảo toàn sắc thái và ngữ cảnh của bình luận, vốn là yếu tố then chốt trong việc phân biệt các lớp nhãn. Nhóm sẽ liên tục cân nhắc các yếu tố này trong quá trình huấn luyện mô hình.

Những phân tích định lượng và định tính này không chỉ giúp nhóm hiểu sâu về bản chất dữ liệu mà còn là cơ sở để lựa chọn các kiến trúc mô hình học máy và phương pháp trích xuất đặc trưng phù hợp trong các giai đoạn tiếp theo của đề án.

Tài liệu

Luu, S. T., Nguyen, K. V., & Nguyen, N. L.-T. (2021). A large-scale dataset for hate speech detection on vietnamese social media texts. In H. Fujita, A. Selamat, J. C.-W. Lin, & M. Ali (Eds.), *Advances and trends in artificial intelligence. artificial intelligence practices* (pp. 415–426). Springer International Publishing.